

Análisis documental, temporal y geoespacial de registros delictivos de Mexicali mediante MongoDB

Reporte final del proyecto

Equipo: Monkeydata

Integrantes:

Guadalupe León Morales

Silvia Alexa Gaona Amaya

Martha Lucía Miranda Arteaga

Conceptos avanzados de bases de datos NoSQL
Manejo de bases de datos SQL y NoSQL en un entorno de nube
Facultad de Ciencias e IIMAS, UNAM

Repositorio: github.com/lupita30leon/proyecto-final-mexicali

1. Problema y datos

El proyecto atiende el análisis de 175,482 registros delictivos del municipio de Mexicali (enero de 2014 a septiembre de 2024), obtenidos del conjunto público **Mexicali Crimes** en Kaggle. El volumen de información y sus atributos categóricos, temporales y geográficos requieren una estructura documental que permita consultarlos de forma organizada y eficiente.

Personas usuarias y decisiones que apoya

- Personal de análisis de datos municipales y planeación de seguridad pública.
- Investigadoras e investigadores de fenómenos urbanos y delictivos.
- Analistas que exploran patrones temporales o territoriales.
- Personal técnico responsable de mantener el sistema de consulta.

Los resultados son exploratorios y agregados: no se usan para estimar el riesgo individual de una persona, vivienda o establecimiento, ni para recomendar operativos o predecir delitos.

Preguntas del proyecto

- ¿Cuáles son las clasificaciones delictivas con mayor número de registros?
- ¿Cómo se distribuyen los registros por año, mes, día de la semana y hora?
- ¿Cuáles son los 20 registros más recientes de robo de vehículo ocurridos durante 2023?
- ¿Cuáles son los 20 registros más recientes de Valle del Pedregal entre 2020 y 2024?
- ¿Cuántos registros de robo de vehículo se encuentran dentro de cinco kilómetros de una ubicación de referencia registrada en Mirasol?

Procedencia y protección de los datos

Fuente: Kaggle, conjunto *Mexicali Crimes*, archivo `crimes_mxl.csv`, incorporado el 14 de agosto de 2026. El archivo original se conserva sin modificaciones; la limpieza y transformación se hacen mediante scripts reproducibles. La fuente no contiene nombres, correos ni teléfonos; las coordenadas se tratan como información potencialmente sensible (ver sección 5).

Modelo documental (resumen)

Un documento por registro, con fechas BSON `Date`, un objeto anidado `lugar` (municipio, nombre, tipo) y una ubicación GeoJSON `Point` opcional (35,019 registros no tienen coordenadas utilizables):

```
{ clasificacionDelito: "HOME ROBBERY", fechaRegistro: ISODate(...), fechaOcurrencia: ISODate(...), lugar: {  
  municipio: "MEXICALI", nombre: "MIRASOL", tipo: "SUBDIVISION" }, ubicacion: { type: "Point", coordinates:  
    [-115.3862048, 32.60621895] } }
```

2. Implementación

Consultas y pipelines principales

Consulta	Resultado principal
Clasificaciones más frecuentes	VEHICLE THEFT: 37,331 registros (1er lugar)
Registros por año	24,480 en 2014 a 8,764 en 2024 (parcial, hasta septiembre)
Registros por hora	12:00 es la hora con más registros: 11,895
Lugares con más robo de vehículo	INDEPENDENCIA: 968 registros (1er lugar)
A: robo de vehículo en 2023 (20 más recientes)	Filtro de igualdad + rango de fecha [inicio, fin)
B: Valle del Pedregal 2020-2024 (20 más recientes)	Filtro de igualdad + rango de fecha [inicio, fin)

Índices y rendimiento

Se crearon dos índices compuestos y un índice geoespacial, derivados de patrones de consulta concretos, no de un campo por índice:

Consulta	Plan antes	nReturned	Keys antes	Docs antes	Plan después	Keys después	Docs después
A. Robo de vehículo 2023	COLLSCAN + SORT	20	0	175,482	IXSCAN cubierto	20	0
B. Valle del Pedregal	COLLSCAN + SORT	20	0	175,482	IXSCAN + FETCH	20	20

¿Por qué la consulta A llega a 0 documentos y 20 llaves examinadas? Los tres campos que la consulta A devuelve (`_id`, `clasificacionDelito`, `fechaOcurriencia`) ya forman parte de las llaves del índice `idx_clasificacion_fecha_id`. MongoDB resuelve toda la consulta leyendo sólo el índice (20 llaves, una por resultado) sin abrir ningún documento de la colección: es un índice cubierto (`PROJECTION_COVERED`). La consulta B necesita `lugar.nombre`, que no es un valor devuelto por su índice, así que sí abre los 20 documentos (`FETCH`) después de ubicar las 20 llaves. Detalle completo en `documentacion/03_indices_rendimiento.md`.




Figura 1. Consulta principal: salida de `explain("executionStats")` de la consulta A antes (`COLLSCAN`, 175,482 docs examinados) y después (`IXSCAN cubierto`, 0 docs examinados) de crear el índice `idx_clasificacion_fecha_id`. Fuente sugerida: `resultados/medicion_antes_indices.txt` y `resultados/medicion_despues_indices.txt`.

Validación y calidad

Validador `$jsonSchema` aplicado mediante `collMod`, con `validationLevel: "strict"` y `validationAction: "error"`. Controla campos obligatorios, tipos BSON, dominios permitidos (16 clasificaciones, municipio único, 3 tipos de lugar), estructura GeoJSON y los intervalos de longitud/latitud mediante una regla de consulta complementaria.

Resultado	Casos
Documentos válidos aceptados	2
Documentos inválidos rechazados (estructura, dominio y GeoJSON)	9
Resultados diferentes de lo esperado	0

3. Análisis especializado

Componente elegido: análisis geoespacial

El componente geoespacial se eligió porque la pregunta 5 del proyecto requiere explícitamente una relación de **proximidad**, algo que ni el análisis temporal ni la búsqueda textual pueden resolver por sí solos. Se usó \$geoNear como primera etapa del pipeline sobre un índice 2dsphere.

Indicador	Resultado
Punto de referencia	MIRASOL: [-115.3862048, 32.60621895]
Radio de búsqueda	5,000 metros
Robos de vehículo dentro del radio	9,513
Distancia promedio	2,721.06 metros
Distancia máxima observada	4,989.75 metros

¿Qué pregunta responde? Dimensiona cuántos reportes de robo de vehículo caen dentro de un radio operativo fijo alrededor de un punto, útil por ejemplo para explorar cobertura de un radio de patrullaje o atención — no para calificar la zona.

¿Por qué Mirasol? Es la misma referencia usada en el modelo documental desde el planteamiento del problema (trazabilidad); varios eventos comparten esa coordenada exacta, lo que permite construir un caso de control verificable a mano; y es una ubicación real dentro del municipio, no un caso extremo. **No** se eligió por ser la colonia con más incidencia: esa comparación entre zonas no se realizó.

Por qué esto no es "mayor riesgo": no existe un denominador de población, vehículos registrados o exposición por zona; no se comparó el mismo indicador contra otros puntos de referencia; y el punto se eligió por reproducibilidad, no por un análisis previo de incidencia. El resultado se limita a un conteo absoluto dentro de un radio fijo.




Figura 2. Análisis especializado: salida de scripts/analisis_geoespacial.js mostrando el pipeline \$geoNear + \$group con el resultado de 9,513 registros, distancia promedio y máxima. Fuente sugerida: resultados/analisis_geoespacial.txt.

Técnicas complementarias y descartadas

Técnica	Decisión	Justificación
Análisis temporal	Integrado como complemento	Las fechas BSON permiten intervalos [inicio, fin), pipelines por mes/día/hora e índices que ya se necesitaban para las consultas A y B; se documenta en documentacion/06_analisis_temporal.md.
Búsqueda con \$text	Descartada	lugar.nombre es un nombre propio corto, no texto libre; \$text tokeniza y puntúa por relevancia, algo pensado para prosa, no para nombres de colonias.
Búsqueda con \$regex	Integrada	Resuelve directamente la coincidencia parcial o de mayúsculas/minúsculas que necesita el caso de uso real (documentacion/10_busqueda.md).
\$geoWithin / \$geoIntersects	Descartadas para esta pregunta	La pregunta 5 requiere proximidad a un punto, no pertenencia a un polígono ni intersección de geometrías.

4. Seguridad y cierre

Clasificación de datos

Campo	Individual	Agregado	Motivo
_id	Interno	Se excluye	Identificador técnico; permite rastrear un documento entre consultas.
clasificacionDelito	Interno	Público	Sola es genérica; combinada con fecha y lugar exactos reconstruye un evento.
fechaOcurrenca	Sensible	Público (año-mes)	La marca exacta facilita correlacionar con fuentes externas.
lugar.nombre	Interno	Público	Cruzado con fecha exacta aumenta el riesgo de reidentificación indirecta.
ubicacion.coordinates	Sensible	Sensible salvo generalizar	Cuasi-identificador espacial de un evento.

Minimización, generalización y enmascaramiento

La vista `vista_publica_delitos` (`scripts/salida_protegida_rol_consulta.js`) excluye `_id` y `ubicacion`, generaliza la fecha a año-mes y entrega sólo conteos agregados por clasificación, colonia y periodo. Es la salida que consume el rol de sólo lectura pública.

Matriz de roles y privilegio mínimo

Rol	Recurso	Operaciones	Lee datos crudos	Escribe	Administra
<code>rol_lectura_publica</code>	<code>vista_publica_delitos</code>	<code>find</code>	No	No	No
<code>rol_analista_interno</code>	<code>delitos_mexicali</code>	<code>find</code>	Sí	No	No
<code>rol_carga_datos</code>	<code>delitos_mexicali</code>	<code>find, insert</code>	Sí	Sólo insertar	No
<code>rol_administrador_indices</code>	<code>delitos_mexicali</code>	<code>createIndex, dropIndex, collMod</code>	No	No	Sí

[Figura 3 — pendiente de captura real]

Capturar el bloque de comparación campo por campo (paso 4 del script) y el diagnóstico de autenticación del script de roles.

Figura 3. Evidencia de índice, validación o protección: salida de `scripts/salida_protegida_rol_consulta.js` comparando un documento crudo de MIRASOL contra su fila equivalente en `vista_publica_delitos`, y/o la salida de `curso.getRoles({showPrivileges:true})` de `scripts/seguridad_rol_acceso.js`. Fuente sugerida: `resultados/salida_protegida_rol_consulta.txt` y `resultados/seguridad_rol_acceso.txt`.

Credenciales y cifrado

Ningún script contiene usuarios ni contraseñas. La conexión de desarrollo es local y sin credenciales (`mongodb://127.0.0.1:27017`); las contraseñas de prueba se leen de variables de entorno (`PASSWORD_ANALISTA`, `PASSWORD_LECTURA`) definidas fuera del repositorio. El laboratorio no cifra tránsito ni almacenamiento porque es un entorno local de un solo usuario; un entorno objetivo en AWS (por ejemplo, Amazon DocumentDB) requeriría TLS obligatorio, cifrado en reposo administrado por el proveedor y un gestor de secretos.

Rol diseñado frente a denegación comprobada

El servidor usado en el desarrollo no tiene `security.authorization: enabled`. Los cuatro roles están **diseñados y son verificables**, pero la **denegación real** de una operación fuera de privilegio sólo se reporta como comprobada si el script detecta autenticación activa y captura el error `not authorized` correspondiente; si no la detecta, lo documenta en vez de asumirlo.

Resultados principales

- VEHICLE THEFT es la clasificación más frecuente, con 37,331 registros.
- Los índices redujeron los documentos examinados de 175,482 a 0 (consulta A, índice cubierto) y a 20 (consulta B).
- 9,513 robos de vehículo se ubican dentro de 5 km del punto de referencia en Mirasol, sin que esto implique mayor riesgo relativo.
- El validador aceptó 2 documentos correctos y rechazó 9 inconsistentes, incluyendo violaciones geográficas.
- La vista `vista_publica_delitos` entrega salida agregada y minimizada para el rol de consulta pública.

Límites

- No hay denominador poblacional ni de exposición para calcular tasas por colonia.
- El año 2024 está incompleto (hasta septiembre).
- No se confirmó la zona horaria de las fechas contra una fuente oficial.
- 35,019 registros no tienen coordenadas y quedan fuera del análisis geoespacial.
- La autenticación no estuvo activa en el entorno de desarrollo, por lo que la denegación de privilegios se diseñó pero no siempre pudo comprobarse en ejecución.

Una mejora posible

Incorporar un denominador de exposición por colonia (por ejemplo, número de vehículos registrados o población estimada) permitiría convertir los conteos geoespaciales y territoriales en tasas comparables entre zonas, en lugar de conteos absolutos que sólo describen el volumen de registros de la fuente.