

PROYECTO FINAL

Análisis de delitos en Mexicali con MongoDB

Modelo documental, rendimiento, calidad y análisis geoespacial

Conceptos avanzados de bases de datos NoSQL
Manejo de bases de datos SQL y NoSQL en un entorno de nube
Facultad de Ciencias e IIMAS, UNAM

Silvia Alexa Gaona Amaya
Martha Lucia Miranda Arteaga
Guadalupe León Morales

Agosto de 2026

Resumen ejecutivo

Este proyecto desarrolla una solución documental en MongoDB para almacenar, consultar y analizar registros delictivos del municipio de Mexicali. La fuente pública Mexicali Crimes, disponible en Kaggle, se transformó desde un archivo CSV hacia una colección con campos anidados, fechas BSON y ubicaciones GeoJSON.

La colección final contiene 175,482 documentos entre enero de 2014 y septiembre de 2024. De ellos, 140,463 incluyen una ubicación utilizable y 35,019 no contienen coordenadas. Se implementaron consultas funcionales, dos índices compuestos, un índice 2dsphere, un validador estricto y análisis temporales y geoespaciales.

RESULTADO CENTRAL La solución completa se reconstruyó en 18 etapas y superó 13 de 13 comprobaciones automáticas. Los índices redujeron la exploración de 175,482 documentos a 0 o 20 documentos en las consultas evaluadas.

Indicador	Resultado
Documentos	175,482
Periodo	2014-01-01 a 2024-09-30
Con ubicación	140,463
Clasificaciones	16
Pruebas de validación	11 correctas
Comprobación final	13 de 13

1. Planteamiento del problema

Los datos contienen información categórica, temporal y territorial que resulta difícil de explorar de forma eficiente si permanece únicamente en una tabla plana. El proyecto busca organizar esa información en una base documental que permita responder preguntas concretas y conservar evidencia reproducible.

1.1 Personas usuarias y decisiones

La solución está dirigida a equipos de análisis municipal, planeación de seguridad pública, investigación urbana y mantenimiento de sistemas de consulta. Puede apoyar la identificación de periodos, clasificaciones y lugares que requieren análisis adicional, sin pretender predecir delitos ni estimar riesgo individual.

1.2 Preguntas de análisis

- ¿Cuáles son las clasificaciones delictivas con más registros?
- ¿Cómo se distribuyen los registros por año, mes, día y hora?
- ¿Cuáles son los registros recientes de robo de vehículo en 2023?
- ¿Cuáles son los registros recientes de Valle del Pedregal entre 2020 y 2024?
- ¿Cuántos robos de vehículo se ubican dentro de cinco kilómetros de una referencia en Mirasol?

2. Fuente y preparación de datos

La fuente fue el conjunto Mexicali Crimes publicado por César LR en Kaggle. El archivo original se conservó como datos/crimes_mxl.csv y se procesó en AWS Academy Learner Lab. La carga utilizó Python 3 y PyMongo 3.11.2 sobre MongoDB Community 4.4.29.

Campo original	Transformación
CRIME_CLASSIFICATION	clasificacionDelito, texto
REGISTRATION_DATE	fechaRegistro, BSON Date

Campo original	Transformación
OCCURRED_DATE + CRIME_TIME	fechaOcurrencia, BSON Date
MUNICIPALITY / CRIME_SCENE / TYPE	objeto anidado lugar
X / Y	ubicacion GeoJSON Point

La primera limpieza elimina el marcador BOM y normaliza los saltos de línea. Después, el cargador transforma cada fila, conserva campos opcionales cuando la fuente no aporta información y crea un documento por registro.

3. Modelo documental

El modelo utiliza una colección principal llamada delitos_mexicali dentro de la base m6_nosql. Los datos territoriales se incrustan en lugar porque pertenecen al registro y se consultan junto con él; no existe una colección externa con identificadores estables que justifique referencias.

```
{
  "clasificacionDelito": "HOME ROBBERY",
  "fechaRegistro": ISODate("2014-01-01T00:00:00Z"),
  "fechaOcurrencia": ISODate("2014-01-01T02:00:00Z"),
  "lugar": {"municipio": "MEXICALI", "nombre": "MIRASOL",
    "tipo": "SUBDIVISION"},
  "ubicacion": {"type": "Point",
    "coordinates": [-115.3862048, 32.60621895]}
}
```

DECISIÓN DE DISEÑO Las fechas se almacenan como BSON Date para admitir rangos, ordenamientos y agregaciones. La ubicación utiliza GeoJSON en orden longitud-latitud para habilitar consultas 2dsphere.

4. Resultados funcionales



Figura 1. Clasificaciones con mayor número de registros. Fuente: resultados del proyecto.

VEHICLE THEFT fue la clasificación más frecuente, con 37,331 registros. Le siguieron HOME ROBBERY con 27,816 y OTHER NONVIOLENT ROBBERIES con 26,985. Estas cifras representan registros de la fuente, no tasas ni estimaciones de todos los delitos ocurridos.

Lugar	Robos de vehículo
INDEPENDENCIA	968
GONZALEZ ORTEGA	899
NUEVA	847
VALLE DEL PEDREGAL	824
CENTRO CIVICO	737

5. Estrategia de índices y rendimiento

Se eligieron dos patrones de consulta estables: robo de vehículo durante 2023 y registros de Valle del Pedregal entre 2020 y 2024. En ambos casos se combinaron igualdad, rango temporal, orden descendente por fecha y un límite de 20 documentos.

idx_clasificacion_fecha_id (clasificacionDelito 1, fechaOcurrancia -1, _id 1) → clasificación + fecha · idx_lugar_fecha_id (lugar.nombre 1, fechaOcurrancia -1, _id 1) → lugar + fecha · idx_ubicacion_2dsphere (ubicacion 2dsphere) → proximidad geográfica.

Consulta	Antes	Después	Cambio
A: VEHICLE THEFT 2023	COLLSKAN • 20 devueltos • 0 keys • 175,482 docs • 92 ms	IXSCAN • 20 devueltos • 20 keys • 0 docs • 0 ms	Consulta cubierta
B: Valle del Pedregal	COLLSKAN • 20 devueltos • 0 keys • 175,482 docs • 92 ms	IXSCAN • 20 devueltos • 20 keys • 20 docs • 0 ms	Reducción de lectura

INTERPRETACIÓN La evidencia principal no es el tiempo aislado, que puede variar por caché y carga del entorno, sino el cambio de COLLSKAN a IXSCAN y la reducción drástica de documentos examinados. En A, los tres campos proyectados ya están en las llaves de idx_clasificacion_fecha_id (consulta cubierta): por eso examina 20 llaves y 0 documentos. En B, lugar.nombre no es un valor del índice, así que tras ubicar las 20 llaves se ejecuta FETCH sobre los 20 documentos.

6. Validación y calidad

La colección utiliza un validador con validationLevel strict y validationAction error. El JSON Schema controla campos obligatorios, tipos BSON, dominios, estructura anidada, geometría Point y exactamente dos coordenadas. Una regla adicional restringe longitud a [-180, 180] y latitud a [-90, 90].

De 11 casos de prueba: 2 documentos válidos aceptados y 9 inválidos rechazados (7 por dominio o estructura, 2 por intervalos geográficos), 0 fallas.

- Todos los documentos contienen clasificación y fechas BSON Date.
- Existen 19 documentos sin nombre de lugar.
- 35,019 documentos no contienen tipo de lugar ni ubicación.
- Los campos ausentes se conservaron como opcionales; no se imputaron valores.

7. Análisis temporal



Figura 2. Registros por año; 2024 incluye únicamente enero-septiembre.



Figura 3. Distribución por día y por mes durante 2023.

El lunes concentra 27,260 registros, la cifra más alta por día de la semana. Entre las horas con más registros aparecen 12:00 (11,895), 08:00 (11,533) y 10:00 (9,140). No se confirmó una zona horaria oficial, por lo que los horarios se interpretan como valores de la fuente.

8. Análisis geoespacial

La cobertura geográfica incluye 140,463 puntos. Todos respetan los intervalos de GeoJSON: longitudes entre -115.594338 y -114.7321086, y latitudes entre 32.18634594 y 32.71268582.

Elemento	Resultado
Referencia	Mirasol [-115.3862048, 32.60621895]
Radio	5,000 metros
Robos de vehículo seleccionados	9,513
Distancia promedio	2,721.06 metros
Distancia máxima observada	4,989.75 metros

La selección se verificó primero por proximidad y después se añadió el filtro VEHICLE THEFT. Un registro CULPABLE INJURIES ubicado en el punto de referencia fue excluido por el filtro temático, mientras que un registro de Pórticos del Valle a 5,032.37 metros fue excluido por distancia. Este resultado responde la pregunta 5 del proyecto —cuántos robos de vehículo caen en un radio fijo desde Mirasol— y sirve para dimensionar cobertura operativa, no para calificar la zona. Mirasol se reutiliza como referencia porque ya aparece en el modelo documental y porque varios eventos comparten esa coordenada, lo que permite construir un caso de control verificable; no se eligió por tener mayor incidencia frente a otras colonias.

LÍMITE ESPACIAL Varios documentos comparten exactamente las mismas coordenadas, lo que sugiere puntos generales o centroides. La proximidad no representa tiempo de viaje, tasa de incidencia ni causalidad. Sin un denominador de población o exposición, tampoco debe leerse como mayor riesgo relativo de una zona.

9. Seguridad y privacidad

La fuente no contiene identificadores personales directos; sin embargo, las ubicaciones y los hechos delictivos pueden ser sensibles. En producción se requerirían autenticación, roles de mínimo privilegio, TLS, cifrado en reposo, respaldos protegidos y auditoría.

Los campos se clasifican como públicos, internos o sensibles: ubicacion.coordinates y la marca de tiempo exacta son sensibles a nivel individual, pero públicas si se generalizan (colonia en vez de coordenada, año-mes en vez de fecha exacta). La vista vista_publica_delitos aplica esa minimización —excluye_id y ubicacion, agrega por clasificación, colonia y mes— para el rol de sólo lectura pública.

Rol	Recurso	Operaciones	Privilegio mínimo
rol_lectura_publica	vista_publica_delitos	find	Sólo agregados
rol_analista_interno	delitos_mexicali	find	Sólo lectura
rol_carga_datos	delitos_mexicali	find, insert	Sin editar/borrar
rol_administrador_indices	delitos_mexicali	createIndex, collMod	Sin leer/escribir datos

- No almacenar llaves privadas, tokens ni credenciales en GitHub.
- Compartir resultados agregados cuando la ubicación exacta pueda generar riesgo.
- Conservar el archivo original sin modificaciones y documentar toda transformación.
- Verificar autoría, licencia y condiciones de redistribución de Kaggle antes de publicar la fuente fuera del contexto académico.
- Las contraseñas de prueba se leen de variables de entorno, nunca del código; un entorno objetivo en AWS requeriría además TLS y cifrado en reposo.
- El servidor de desarrollo no tiene autenticación activa: los roles están diseñados y son verificables, pero la denegación de privilegios sólo se reporta como comprobada cuando el script detecta autenticación activa y la confirma con un error de autorización real.

10. Reproducibilidad

El repositorio contiene scripts independientes y un ejecutor general protegido por la opción --confirmar. La reconstrucción completa se ejecutó desde la fuente y terminó sin errores.

Preparación y carga (preparar_csv.sh, cargar_mongodb.py) · Consultas e índices (consultas_funcionales.js, crear_indices.js) · Calidad (aplicar_validador.js, pruebas de validación) · Análisis (analisis_geoespacial.js, analisis_temporal.js) · Cierre (evidencia_final.js, 13 de 13 comprobaciones).

bash scripts/ejecutar_proyecto.sh --confirmar

Evidencia de ejecución

Capturas reales de la ejecución en AWS Academy Learner Lab, correspondientes a los resultados citados en este reporte.



Consulta A: plan IXSCAN, 0 docs examinados, 20 llaves.



Geoespacial: 9,513 robos de vehículo en 5 km de Mirasol.



Documento crudo vs. vista_publica_delitos minimizada.



Comprobación final: 13 de 13 correctas.

11. Limitaciones

- Los datos representan registros disponibles, no todos los delitos ocurridos, y no existe un denominador de población o exposición para calcular tasas.
- El año 2024 está incompleto (no debe compararse como año completo) y no se confirmó la zona horaria de las fechas.
- 35,019 documentos no contienen ubicación y las coordenadas compartidas limitan la precisión espacial.
- Las asociaciones temporales o espaciales no demuestran causalidad.

12. Conclusiones

MongoDB resultó adecuado para representar registros con atributos categóricos, fechas y ubicaciones. El modelo documental simplificó la lectura, los índices redujeron el trabajo de las consultas y el validador protegió la estructura y los dominios establecidos.

El proyecto demuestra una solución funcional y reproducible: 175,482 documentos, tres índices especializados, 11 pruebas de validación sin fallas y 13 comprobaciones finales correctas. Los resultados permiten explorar la información de forma consistente, siempre que se respeten las limitaciones de cobertura, precisión e interpretación.

CONCLUSIÓN FINAL El valor del proyecto no reside únicamente en producir conteos, sino en conectar preguntas relevantes con un modelo, consultas, índices, reglas y evidencia que otra persona puede volver a ejecutar.

Referencias

- César LR. Mexicali Crimes. Kaggle. <https://www.kaggle.com/datasets/cesarlr/mexicali-crimes>
- Repositorio del proyecto. <https://github.com/lupita30leon/proyecto-final-mexicali>
- Soto Romero, Manuel. Guía de avance del proyecto final, Semana 2: Rendimiento y calidad de los datos. UNAM, 2026.
- Soto Romero, Manuel. Guía de avance del proyecto final, Semana 3: Datos en el mapa. UNAM, 2026.